

Wykrywanie naczyń krwionośnych dna siatkówki oka

Anna Żurczak 127227

Patryk Glapiak 127233

Przetwarzanie obrazu

Na początku wczytywany jest tylko kanał zielony. Następnie na obraz jest nakładany filtr Frangi'ego specjalizujący się w wykrywaniu naczyń na zdjęciach. Wyjściowy obraz poddawany jest progowaniu.

Efekty:


Nr zdj Cecha	6	7	8	9	10
Sensitivity	0.791	0.713	0.739	0.704	0.716
Specificity	0.981	0.988	0.988	0.984	0.983
Accuracy	0.962	0.964	0.963	0.962	0.961

Dla zdjęcia nr 8:


Oryginalne zdjęcie:



Maska ekspercka:



Uzyskany efekt:




Klasyfikator odległościowy – kNN

Po wycięciu zielonego kanału tworzymy zbiór decyzyjny dla klasyfikatora odległościowego. Losujemy 1/1000 pikseli z obrazka nr 8 i liczymy dla nich i ich sąsiadów medianę, wariancję i średnią i dla odpowiadającego piksela z maski eksperckiej zapamiętujemy jego wartość. Zachowujemy proporcje w zbiorze decyzyjnym 50% białych pikseli i 50% czarnych pikseli. Korzystając z funkcji `KNeighborsClassifier` z biblioteki `sklearn.neighbors` tworzymy klasyfikator. Parametr `k` ustawiliśmy na wartość 5, co oznacza, że bierzemy 5 najbliższych sąsiadów piksela. Obraz wyjściowy uzyskujemy licząc na obrazie wejściowym te same parametry co dla zbioru decyzyjnego, a funkcja `predict` z `sklearn.neighbors` znajduje najlepsze dopasowanie. Na końcu zastosowano erozję, w celu usunięcia szumów.


Efekty:

Nr zdj Cecha	6	7	8	9	10
Sensitivity	0,769	0,652	0.529	0,651	0,657
Specificity	0,787	0,827	0,937	0,850	0,769
Accuracy	0,785	0,811	0,896	0,835	0,759


Dla zdjęcia nr 8:
Przed erozją:




Po erozji:



Dla zdjęcia nr 7 uczącego się ze zdjęcia nr 8:
Przed erozją:



Po erozji:



Wnioski

W przypadku przetwarzania obrazu filtr Frangi'ego rozpoznał poprawnie około 70% naczyń krwionośnych, a ogólna klasyfikacja wyszła +/- 96% co daje zadowalający efekt. Naczynia nierozpoznane to te, które są zbyt jasne i cienkie.

Dla klasyfikatora kNN bardzo dobry efekt uzyskaliśmy, gdy uczył się i przetwarzał to samo zdjęcie. W przypadku przedstawionego zdjęcia nr 7, gdzie działamy na klasyfikatorze utworzonym na podstawie zdjęcia nr 8, występuje więcej białych pojedynczych punktów w miejscach, w których powinno być tło. Próbowaliśmy manipulować ilością zebranych danych do klasyfikatora i proporcja czarnych i białych pikseli, jednak nie dawało to znaczącej poprawy.

Porównując miary efektywności, zwykłe przetwarzanie obrazu uzyskało średnio lepszy wynik końcowy o ok. 5-10% od klasyfikatora kNN.